

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN, ĐHQG-HCM
KHOA KHOA HỌC MÁY TÍNH



BÁO CÁO ĐỒ ÁN MÔN HỌC
DỰ ĐOÁN KHẢ NĂNG KHÁCH HÀNG ĐĂNG KÝ TIỀN GỬI CÓ KỲ
HẠN BẰNG MACHINE LEARNING

Môn học: CS114.Q22 - Máy Học
Giảng viên hướng dẫn: Võ Nguyễn Lê Duy

Danh sách thành viên thực hiện:

Nguyễn Trần Gia Bảo	23520129	Trưởng nhóm
Phạm Văn Thái	22521320	Thành viên
Đinh Đức Tiến	22521462	Thành viên
Hứa Xuân Vinh	22521667	Thành viên
Trương Quốc Vinh	22521682	Thành viên
Nguyễn Bùi Nhật Anh	23520056	Thành viên

TP. Hồ Chí Minh, 2026

MỤC LỤC

Tóm tắt	2
CHƯƠNG 1: Giới thiệu đề tài	3
CHƯƠNG 2: Dataset và phân tích khám phá dữ liệu	3
CHƯƠNG 3: Tiền xử lý và tạo đặc trưng	5
CHƯƠNG 4: Xây dựng mô hình	6
CHƯƠNG 5: Kết quả thực nghiệm	7
CHƯƠNG 6: Web demo, kết luận và hướng phát triển	9

TÓM TẮT

Báo cáo trình bày quy trình xây dựng hệ thống dự đoán khả năng khách hàng đăng ký tiền gửi có kỳ hạn dựa trên bộ dữ liệu Bank Marketing của UCI. Nhóm thực hiện lại quá trình kiểm tra dữ liệu, tiền xử lý, huấn luyện và đánh giá mô hình từ các file trong thư mục Project after fixed nhằm bảo đảm nội dung báo cáo khớp với kết quả thực nghiệm.

Dữ liệu sau xử lý có 41.176 dòng và 58 cột, tỷ lệ khách hàng đăng ký chỉ đạt 11,27%, do đó bài toán có mất cân bằng lớp rõ rệt. Kết quả chính được báo cáo theo kịch bản realistic, không dùng biến duration vì biến này chỉ biết sau khi cuộc gọi kết thúc. Trong các mô hình đã thử nghiệm, Random Forest đạt PR-AUC 0,5134 và F1 0,5332 ở kịch bản realistic, phù hợp khi mục tiêu là không bỏ sót khách hàng tiềm năng.

Bộ dữ liệu gốc gồm bốn nhóm thông tin chính. Nhóm thứ nhất là thông tin nhân khẩu học và tài chính của khách hàng như age, job, marital, education, default, housing và loan. Nhóm thứ hai mô tả cách liên hệ trong chiến dịch hiện tại như contact, month, day_of_week, duration và campaign. Nhóm thứ ba phản ánh lịch sử chiến dịch trước đó như pdays, previous và poutcome. Nhóm cuối cùng là các biến kinh tế vĩ mô gồm emp.var.rate, cons.price.idx, cons.conf.idx, euribor3m và nr.employed.

Cách chia nhóm này giúp giải thích kết quả mô hình rõ hơn: các biến khách hàng mô tả khả năng phù hợp với sản phẩm, các biến chiến dịch mô tả cách ngân hàng tiếp cận, còn nhóm vĩ mô phản ánh bối cảnh kinh tế tại thời điểm liên hệ. Việc giữ lại đầy đủ các nhóm feature giúp mô hình không chỉ dựa vào một nguồn tín hiệu đơn lẻ.

DANH MỤC BẢNG VÀ HÌNH

- *Bảng 1. Thông tin tổng quan bộ dữ liệu và kết quả kiểm chứng.*
- *Bảng 2. Output contract của notebook tiền xử lý.*
- *Bảng 3. Kết quả Logistic Regression theo hai kịch bản.*
- *Bảng 4. So sánh mô hình ở kịch bản realistic. Hình 1-5. Pipeline, phân phối mục tiêu, chất lượng dữ liệu, so sánh mô hình và feature importance.*

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

1.1. Tính cấp thiết của đề tài

Trong hoạt động marketing ngân hàng, chi phí gọi điện và chăm sóc khách hàng thường lớn, trong khi tỷ lệ khách hàng thật sự đăng ký sản phẩm lại thấp. Nếu có thể ước lượng trước khả năng đăng ký của từng khách hàng, ngân hàng có thể ưu tiên nhóm có xác suất chuyển đổi cao, giảm số cuộc gọi không hiệu quả và cải thiện chất lượng chiến dịch.

Bộ dữ liệu Bank Marketing phản ánh một bài toán thực tế: dự đoán khách hàng có đăng ký tiền gửi có kỳ hạn hay không dựa trên thông tin cá nhân, lịch sử liên hệ, thông tin chiến dịch và bối cảnh kinh tế. Đây là bài toán phân loại nhị phân nhưng có nhiều khó khăn như mất cân bằng lớp, thay đổi phân phối theo thời gian và nguy cơ data leakage từ biến duration.

1.2. Mục tiêu nghiên cứu

- Phân tích dữ liệu Bank Marketing và xác định các vấn đề ảnh hưởng đến mô hình học máy.
- Xây dựng tập dữ liệu đã xử lý có thể dùng lại cho các notebook mô hình và web demo.
- So sánh Logistic Regression, Random Forest, XGBoost và LightGBM theo cùng một quy trình temporal split.
- Xây dựng web demo Streamlit để minh họa quá trình khám phá dữ liệu, huấn luyện và dự đoán.

1.3. Phạm vi và tiêu chí đánh giá


Báo cáo tập trung vào kịch bản dự đoán trước cuộc gọi. Vì vậy, biến duration được giữ trong dữ liệu đã xử lý để làm benchmark, nhưng bị loại khỏi kết quả chính. Các chỉ số được sử dụng gồm ROC-AUC, PR-AUC, precision, recall, F1-score và balanced accuracy. Accuracy không được xem là chỉ số chính vì lớp yes chỉ chiếm khoảng 11,27%.

1.4. Cơ sở lý thuyết của bài toán

Bài toán được mô hình hóa dưới dạng phân loại nhị phân, trong đó nhãn 1 biểu diễn khách hàng đăng ký tiền gửi và nhãn 0 biểu diễn khách hàng không đăng ký. Khác với bài toán phân loại cân bằng, mô hình ở đây phải nhận diện được lớp thiểu số có giá trị nghiệp vụ cao. Vì vậy, mục tiêu không chỉ là dự đoán đúng đa số khách hàng từ chối, mà còn phải tìm được nhóm khách hàng có xác suất đăng ký đủ cao để ngân hàng ưu tiên liên hệ.

Một đặc điểm quan trọng của dữ liệu chiến dịch là thứ tự thời gian. Thông tin ở giai đoạn sau có thể phản ánh điều kiện thị trường khác hẳn giai đoạn đầu, đặc biệt khi các biến vĩ mô như euribor3m, emp.var.rate và nr.employed thay đổi. Do đó, temporal split được lựa chọn thay cho random split để kiểm tra khả năng tổng quát hóa của mô hình trên dữ liệu tương lai.

Pipeline xử lý và đánh giá mô hình



Hình 1. Quy trình tổng quát từ dữ liệu gốc đến đánh giá mô hình.

CHƯƠNG 2: DATASET VÀ PHÂN TÍCH KHÁM PHÁ DỮ LIỆU

2.1. Giới thiệu bộ dữ liệu

Dữ liệu được lấy từ gói UCI Bank Marketing. Nhóm sử dụng nhánh bank-additional-full.csv vì tập này có thêm các biến kinh tế vĩ mô, phù hợp hơn cho việc giải thích và mô hình hóa so với nhánh


bank-full.csv. Mỗi dòng tương ứng với một lượt liên hệ khách hàng trong chiến dịch marketing qua điện thoại.

Nội dung	Kết quả kiểm chứng
Dữ liệu gốc	41.188 dòng, 20 biến đầu vào và 1 biến mục tiêu
Dòng trùng lặp	12 dòng trùng chính xác, đã loại bỏ
Dữ liệu sau xử lý	41.176 dòng, 58 cột
Missing NaN	Không có NaN trong file processed_bank_data.csv
Phân phối mục tiêu	no: 36.537 mẫu; yes: 4.639 mẫu
File đầu ra	Models/processed_bank_data.csv và Models/preprocessing_summary.json

Bảng 1. Thông tin tổng quan bộ dữ liệu và kết quả kiểm chứng.

2.2. Phân phối biến mục tiêu

Sau khi loại dòng trùng, lớp không đăng ký chiếm 88,73%, trong khi lớp đăng ký chỉ chiếm 11,27%. Mất cân bằng lớp này khiến mô hình có thể đạt accuracy cao bằng cách dự đoán đa số là no, nhưng lại bỏ sót khách hàng tiềm năng. Vì vậy, các chỉ số tập trung vào lớp yes như PR-AUC, recall và F1 được ưu tiên trong phần đánh giá.




Hình 2. Phân phối biến mục tiêu sau tiền xử lý.

2.3. Chất lượng dữ liệu và drift theo thời gian

Dữ liệu không có missing thật dưới dạng NaN, nhưng có nhiều giá trị unknown trong các biến phân loại. Notebook tiền xử lý giữ unknown như một category hợp lệ thay vì tự động điền giá trị, vì trạng thái này có thể mang thông tin vận hành của hệ thống ngân hàng. Biến default có nhiều unknown nhất với 8.597 dòng, tiếp theo là education, housing và loan.

Một phát hiện quan trọng từ EDA là dữ liệu có drift theo thứ tự thời gian. Tỷ lệ yes trong train là 5,58%, validation là 11,97% và test là 30,83%. Nếu dùng random split, kết quả có thể quá lạc quan do trộn dữ liệu tương lai vào quá trình học. Vì vậy, nhóm dùng temporal split để mô phỏng đúng hơn tình huống triển khai.



Hình 3. Giá trị unknown trong dữ liệu gốc và tỷ lệ yes theo temporal split.

2.4. Quan hệ giữa đặc trưng và biến mục tiêu

Notebook EDA cho thấy poutcome là biến phân loại có liên hệ mạnh nhất với y. Nhóm khách hàng có kết quả chiến dịch trước là success có tỷ lệ đăng ký khoảng 65,11%, cao hơn rất nhiều so với nhóm nonexistent chỉ khoảng 8,83%. Điều này hợp lý về mặt nghiệp vụ vì khách hàng từng phản hồi tích cực trong quá khứ thường có khả năng tiếp tục quan tâm đến sản phẩm ngân hàng.

Theo tháng liên hệ, các tháng mar, dec, sep và oct có tỷ lệ yes cao hơn đáng kể so với các tháng còn lại, trong khi các tháng có khối lượng liên hệ lớn như may hoặc jul không nhất thiết đem lại tỷ lệ chuyển đổi cao. Với biến contact, liên hệ qua cellular đạt tỷ lệ yes khoảng 14,74%, cao hơn telephone khoảng 5,23%. Các quan sát này hỗ trợ việc giữ lại month và contact trong mô hình.

Ở nhóm biến số, duration có Pearson correlation với y khoảng 0,4053, là tín hiệu rất mạnh nhưng không phù hợp cho kịch bản pre-call. Các biến vĩ mô như nr.employed, euribor3m và emp.var.rate có tương quan âm đáng kể với y, cho thấy bối cảnh kinh tế tác động rõ đến xác suất khách hàng đăng ký. Ngoài ra, previous và pdays thể hiện thông tin lịch sử liên hệ, góp phần bổ sung tín hiệu hành vi khách hàng.

2.5. Các insight chính từ EDA

- duration có tương quan mạnh với y nhưng gây leakage nếu dùng cho dự đoán trước cuộc gọi.
- Các biến phân loại đáng chú ý gồm poutcome, month, contact và job.
- Nhóm biến kinh tế vĩ mô như euribor3m, emp.var.rate và nr.employed có ảnh hưởng lớn đến kết quả dự đoán.
- Dữ liệu không thuần tuyến tính; các mô hình cây có thể khai thác tương tác phi tuyến tốt hơn baseline tuyến tính.

CHƯƠNG 3: TIỀN XỬ LÝ VÀ TẠO ĐẶC TRƯNG

3.1. Quy trình tiền xử lý

Notebook preprocessing.ipynb được xây dựng lại để chạy bằng đường dẫn tương đối, không phụ thuộc Google Drive hoặc máy cá nhân. Notebook đọc dữ liệu trực tiếp từ file zip gốc, loại bỏ dòng trùng, mã hóa biến mục tiêu và xuất ra file processed_bank_data.csv cho toàn bộ phần mô hình và web demo.

- Loại bỏ 12 dòng trùng lặp chính xác trước khi encoding.
- Mã hóa biến y: yes thành 1 và no thành 0.
- Tạo age_group từ age với các nhóm young, adult, middle và senior.
- Tạo is_contacted_before từ pdays, trong đó pdays = 999 nghĩa là chưa từng được liên hệ trước đó.

- One-hot encoding các biến phân loại với `drop_first=True`, tạo dữ liệu numeric/boolean sẵn sàng cho mô hình.

3.2. Kiểm soát data leakage

Biến `duration` được giữ trong file `processed` để phục vụ benchmark, nhưng không được dùng trong kịch bản chính. Lý do là `duration` chỉ biết sau khi cuộc gọi kết thúc; nếu mục tiêu là quyết định có nên gọi khách hàng hay không, biến này không tồn tại tại thời điểm dự đoán. Báo cáo vì vậy tách rõ hai kịch bản: `with duration` để xem giới hạn hiệu năng, và `without duration` để phản ánh triển khai thực tế.

3.3. Chuẩn bị dữ liệu cho modeling

Sau preprocessing, dữ liệu được giữ ở dạng numeric/boolean để các notebook mô hình có thể đọc trực tiếp mà không cần xử lý lại dữ liệu thô. Với Logistic Regression, các feature được chuẩn hóa bằng `StandardScaler` trong pipeline để tránh biến có thang đo lớn chi phối quá trình tối ưu. Với các mô hình cây, chuẩn hóa không bắt buộc về mặt thuật toán nhưng pipeline vẫn được tổ chức thống nhất để kiểm soát luồng dữ liệu.

SMOTE không được áp dụng ở bước tạo file `processed_bank_data.csv` mà được đặt trong pipeline huấn luyện. Cách này quan trọng vì SMOTE chỉ được fit trên phần train trong từng lần huấn luyện hoặc cross-validation. Nếu oversampling được làm trước khi chia tập, các điểm tổng hợp có thể mang thông tin từ validation/test, làm kết quả bị lạc quan không đúng thực tế.

3.4. Output contract

Thành phần	Mô tả
<code>processed_bank_data.csv</code>	41.176 dòng, 58 cột; không có NaN; gồm target <code>y</code> và các feature đã encoding.
<code>preprocessing_summary.json</code>	Lưu shape dữ liệu gốc, số dòng trùng đã bỏ, shape dữ liệu sau xử lý và policy về <code>duration</code> .
<code>is_contacted_before</code>	Feature mới cho biết khách hàng từng được liên hệ trong chiến dịch trước hay chưa.
<code>age_group *</code>	Các dummy feature biểu diễn nhóm tuổi để hỗ trợ quan hệ phi tuyến đơn giản.

Bảng 2. Kết quả đầu ra của notebook tiền xử lý.

Điểm đã điều chỉnh so với bản nháp cũ: preprocessing không thực hiện correlation-based feature selection. Việc loại `duration` chỉ được thực hiện ở bước modeling cho kịch bản `realistic`, còn các feature khác được giữ để mô hình tự học trọng số hoặc importance.

CHƯƠNG 4: XÂY DỰNG MÔ HÌNH

4.1. Thiết kế thực nghiệm

Dữ liệu được chia theo thứ tự thời gian với tỷ lệ 70/10/20. Tập train dùng để học mô hình, tập validation dùng để chọn threshold, và tập test chỉ dùng một lần để báo cáo kết quả cuối cùng. Sau khi chọn threshold, mô hình được refit trên `train + validation` trước khi đánh giá trên test.

SMOTE được đặt trong `imblearn.Pipeline` để chỉ fit trên dữ liệu huấn luyện. Cách làm này tránh tình huống mẫu tổng hợp từ lớp thiểu số bị tạo dựa trên thông tin của validation hoặc test. Với Logistic Regression, `StandardScaler` được dùng trước khi huấn luyện. Với các mô hình cây, notebook nâng cao vẫn giữ pipeline thống nhất để đánh giá công bằng.

4.2. Chỉ số đánh giá và chọn threshold

ROC-AUC đo khả năng xếp hạng mẫu dương cao hơn mẫu âm trên toàn bộ ngưỡng phân loại. PR-AUC tập trung hơn vào lớp dương, do đó phù hợp với bài toán mất cân bằng khi nhóm `yes` chiếm tỷ lệ nhỏ. Precision cho biết trong các khách hàng được dự đoán sẽ đăng ký có bao nhiêu người thật sự đăng ký; recall cho biết mô hình bắt được bao nhiêu khách hàng đăng ký trong toàn bộ lớp `yes`.

F1-score là trung bình điều hòa giữa precision và recall, dùng để đánh giá sự cân bằng giữa gọi nhầm và bỏ sót. Balanced accuracy lấy trung bình recall của hai lớp, giúp tránh tình trạng mô hình

thiên về lớp no. Trong đồ án này, threshold không cố định ở 0,5 mà được chọn trên validation để phản ánh mục tiêu nghiệp vụ: có thể ưu tiên recall nếu muốn không bỏ sót khách hàng tiềm năng, hoặc ưu tiên precision nếu muốn giảm chi phí gọi nhầm.

4.3. Baseline Logistic Regression

Logistic Regression được chọn làm baseline vì dễ diễn giải hệ số và giúp kiểm tra tín hiệu tuyến tính trong dữ liệu. Kết quả final test sau khi chọn threshold trên validation như sau:

Kịch bản	Thr.	ROC-AUC	PR-AUC	Precision	Recall	F1	Bal. Acc
Có duration - benchmark	0,64	0,7171	0,5292	0,6076	0,3726	0,4619	0,6327
Không duration - realistic	0,70	0,6504	0,4614	0,5084	0,4391	0,4713	0,6250

Bảng 3. Kết quả Logistic Regression ở hai kịch bản đánh giá.

Ở kịch bản realistic, Logistic Regression đạt ROC-AUC 0,6504 và F1 0,4713. Các hệ số có độ lớn cao gồm euribor3m, nr.employed, emp.var.rate, cons.conf.idx và month_nov, cho thấy tín hiệu kinh tế vĩ mô đóng vai trò đáng kể trong bài toán.

4.4. Các mô hình nâng cao

Random Forest được sử dụng để khai thác tương tác phi tuyến giữa các đặc trưng và giảm phụ thuộc vào giả định tuyến tính. Mô hình này kết hợp nhiều cây quyết định trên các mẫu và tập feature khác nhau, nhờ đó có khả năng ổn định hơn một cây đơn lẻ. Trong notebook đã fixed, Random Forest được tuning các tham số như số cây, độ sâu cây, số mẫu tối thiểu ở lá và max_features.

XGBoost và LightGBM là hai mô hình boosting, xây dựng nhiều cây tuần tự để sửa lỗi của các cây trước. XGBoost thường mạnh ở khả năng kiểm soát overfitting thông qua regularization, subsampling và learning rate; LightGBM tối ưu tốc độ huấn luyện và thường hiệu quả với dữ liệu bảng. Việc đưa cả ba mô hình nâng cao vào so sánh giúp đánh giá liệu quan hệ phi tuyến có cải thiện đáng kể so với Logistic Regression hay không.


CHƯƠNG 5: KẾT QUẢ THỰC NGHIỆM

5.1. So sánh các mô hình realistic

Notebook XGBoost_RF_LightGBM.ipynb đánh giá XGBoost, Random Forest và LightGBM với RandomizedSearchCV(error_score="raise"), TimeSeriesSplit và threshold được chọn trên validation. Bảng dưới tổng hợp kết quả final test ở kịch bản không dùng duration.

Mô hình	Thr.	ROC-AUC	PR-AUC	Precision	Recall	F1	Bal. Acc
Logistic Regression	0,70	0,6504	0,4614	0,5084	0,4391	0,4713	0,6250
XGBoost	0,22	0,6979	0,4926	0,5378	0,3923	0,4537	0,6210
Random Forest	0,11	0,7321	0,5134	0,3742	0,9275	0,5332	0,6181
LightGBM	0,23	0,6289	0,4196	0,4597	0,3167	0,3750	0,5754

Bảng 4. So sánh mô hình ở kịch bản realistic.




Hình 4. So sánh ROC-AUC, PR-AUC và F1 giữa các mô hình realistic.

Random Forest đạt PR-AUC và F1 cao nhất trong kịch bản realistic. Điểm mạnh của mô hình là recall lớp yes rất cao, phù hợp khi mục tiêu nghiệp vụ là hạn chế bỏ sót khách hàng tiềm năng. Tuy nhiên, precision thấp vì threshold 0,11 làm mô hình dự đoán nhiều khách hàng là yes hơn. Nếu muốn giảm số cuộc gọi sai, XGBoost là lựa chọn cân bằng hơn nhờ precision cao hơn.

Khi nhìn vào kết quả chi tiết, Random Forest realistic đạt recall lớp yes 0,9275 nhưng precision chỉ 0,3742. Điều này nghĩa là mô hình bắt được phần lớn khách hàng thật sự đăng ký, nhưng đánh đổi bằng việc gắn nhãn yes cho nhiều khách hàng không đăng ký. Đây không phải lỗi tuyệt đối; nó phản ánh lựa chọn threshold thiên về recall. Trong bối cảnh ngân hàng muốn mở rộng danh sách khách hàng tiềm năng để đội sale tiếp tục lọc thủ công, cấu hình này có thể chấp nhận được.

Ngược lại, XGBoost realistic có precision 0,5378 và recall 0,3923. Mô hình này bỏ sót nhiều khách hàng đăng ký hơn Random Forest, nhưng các dự đoán yes có độ tin cậy cao hơn. Vì vậy, nếu chiến dịch bị giới hạn số cuộc gọi hoặc muốn giảm phiền nhiễu cho khách hàng, XGBoost là phương án thực dụng hơn. Báo cáo vì vậy không kết luận một mô hình tốt tuyệt đối, mà gắn kết quả với mục tiêu vận hành cụ thể.

5.2. Diễn giải mô hình tốt nhất



Hình 5. Top feature importance của Random Forest ở kịch bản realistic.

Các feature quan trọng nhất của Random Forest realistic gồm campaign, housing_yes, euribor3m, default_unknown, cons.conf.idx và age. Điều này phù hợp với EDA: quyết định đăng ký không chỉ phụ thuộc vào thông tin khách hàng mà còn liên quan đến lịch sử chiến dịch và bối cảnh kinh tế tại thời điểm liên hệ.

Feature campaign có importance cao nhất, cho thấy số lần khách hàng được liên hệ trong chiến dịch hiện tại ảnh hưởng mạnh đến xác suất chuyển đổi. Tuy nhiên, campaign cao không luôn mang nghĩa tích cực; nhiều lần liên hệ có thể phản ánh khách hàng khó thuyết phục hoặc chiến dịch đang cố gắng tiếp cận lại. Vì vậy, feature importance cần được đọc như mức độ đóng góp vào quyết định của mô hình, không phải luôn là quan hệ nhân quả một chiều.

Các feature như euribor3m và cons.conf.idx xuất hiện trong nhóm quan trọng xác nhận vai trò của bối cảnh kinh tế. Khi môi trường lãi suất và niềm tin tiêu dùng thay đổi, hành vi gửi tiền của khách hàng cũng thay đổi. Điều này giải thích vì sao mô hình đánh giá bằng temporal split khó hơn random split: tập test nằm ở giai đoạn có tỷ lệ yes cao hơn và bối cảnh vĩ mô khác rõ rệt so với train.

CHƯƠNG 6: WEB DEMO, KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Web demo Streamlit

Web demo trong thư mục Web Demo triển khai bằng Streamlit, sử dụng processed_bank_data.csv và hỗ trợ năm trang: Home, Data Exploration, Model Training, Make Predictions và Model Comparison. Ứng dụng cho phép xem thống kê dữ liệu, biểu đồ phân phối, huấn luyện mô hình, nhập hồ sơ khách hàng để dự đoán xác suất đăng ký và so sánh nhiều thuật toán.

Ứng dụng đã được sửa đường dẫn dữ liệu để có thể chạy từ project root hoặc trực tiếp trong thư mục Web Demo. Lệnh chạy chính là: `python -m streamlit run "Web Demo/app.py"`. Các thư viện cần thiết được liệt kê trong Web Demo/requirements.txt.

Về kiến trúc, app.py đóng vai trò giao diện chính, config.py lưu các tham số và đường dẫn cấu hình, còn utils.py chứa các hàm phụ trợ cho metric, biểu đồ và diễn giải dự đoán. Web demo đọc dữ liệu đã xử lý, chia train/test không shuffle, chuẩn hóa dữ liệu, áp dụng SMOTE khi huấn luyện và hiển thị kết quả bằng bảng metric, confusion matrix, ROC/PR curve và feature importance.

Trang Make Predictions cho phép nhập thông tin khách hàng và trả về xác suất đăng ký. Đây là phần mô phỏng cách mô hình có thể được dùng trong thực tế: nhân viên marketing không chỉ nhận nhận yes/no, mà còn có xác suất để sắp xếp thứ tự ưu tiên liên hệ. Với mô hình cây, app có hỗ trợ SHAP nếu môi trường cài đặt đầy đủ; nếu không, hệ thống vẫn có cơ chế giải thích xấp xỉ dựa trên feature importance.

6.2. Kết luận và hướng phát triển

Đồ án đã hoàn thành pipeline từ EDA, preprocessing, modeling đến web demo. Kết quả cho thấy dữ liệu Bank Marketing có mất cân bằng lớp và drift theo thời gian, vì vậy temporal split và các chỉ số như PR-AUC, recall và F1 quan trọng hơn accuracy. Kết quả chính phải dựa trên kịch bản không dùng duration để tránh data leakage.

Trong các mô hình đã kiểm chứng, Random Forest phù hợp khi ưu tiên recall, còn XGBoost phù hợp hơn khi cần cân bằng precision và recall. Hướng phát triển tiếp theo là calibration xác suất, tối ưu threshold theo chi phí kinh doanh thật, lưu model final để web demo dùng đúng pipeline đã chọn và bổ sung giải thích dự đoán ở cấp từng khách hàng bằng SHAP hoặc phương pháp tương đương.

6.3. Hạn chế của đồ án

Hạn chế lớn nhất của bộ dữ liệu là thứ tự dòng chỉ được dùng như đại diện cho thời gian, trong khi dữ liệu không có timestamp đầy đủ ở mức ngày-tháng-năm cho từng cuộc gọi. Vì vậy, temporal split giúp mô phỏng triển khai tốt hơn random split nhưng vẫn chưa hoàn toàn tương đương một hệ thống production. Ngoài ra, dữ liệu đến từ một chiến dịch cụ thể nên mô hình có thể cần huấn luyện lại nếu áp dụng cho ngân hàng, quốc gia hoặc giai đoạn kinh tế khác.

Một hạn chế khác là web demo hiện chủ yếu huấn luyện trực tiếp khi người dùng chọn mô hình, chưa lưu model final đã được calibration và chọn threshold theo chi phí kinh doanh thật. Trong triển khai thực tế, nhóm nên lưu pipeline đã fit, theo dõi drift định kỳ, đánh giá calibration của xác suất và thiết kế threshold theo chi phí cụ thể của một cuộc gọi, lợi nhuận kỳ vọng và mức độ chấp nhận làm phiền khách hàng.

TÀI LIỆU THAM KHẢO

- UCI Machine Learning Repository - Bank Marketing Dataset.
- Notebook bank_marketing_eda.ipynb, preprocessing.ipynb, Logistic_Regression.ipynb và XGBoost_RF_LightGBM.ipynb trong thư mục Project after fixed.
- Tài liệu scikit-learn, imbalanced-learn, XGBoost, LightGBM và Streamlit.
- Moro, S., Cortez, P., & Rita, P. (2014). A Data-Driven Approach to Predict the Success of Bank Telemarketing. Decision Support Systems.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research.